Министерство науки и высшего образования Российской Федерации Федеральное государственное автономное образовательное учреждение высшего образования «СЕВЕРО-КАВКАЗСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

Институт перспективной инженерии Департамент цифровых, робототехнических систем и электроники

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №5

дисциплины «Искусственный интеллект и машинное обучение» Вариант 9

	выполнил: Кравчук Мирослав Витальевич 2 курс, группа ИТС-б-о-23-1, 11.03.02«Инфокоммуникационные			
	технологии и системы связи», очная форма обучения			
	(подпись)			
	Проверил: Доцент департамента цифровых, робототехнических систем и электроники Воронкин Р.А.			
	(подпись)			
Отчет защищен с оценкой	Дата защиты			

Тема работы: "Введение в pandas: изучение структуры DataFrame и базовых операций".

Цель работы: ознакомить с основами работы с библиотекой pandas, в частности, со структурой данных DataFrame.

Ссылка на git репозиторий: https://github.com/miron2314/DLab-5.git

Порядок выполнения работы:

1. Создание DataFrame разными способами.

```
data = {
    "ID": [1, 2, 3, 4, 5],
    "Имя": ["Иван", "Ольга", "Алексей", "Мария", "Сергей"],
    "Возраст": [25, 30, 40, 35, 28],
    "Должность": ["Инженер", "Аналитик", "Менеджер", "Программист", "Специалист"],
    "Отдел": ["IT", "Маркетинг", "Продажи", "IT", "HR"],
    "Зарплата": [60000, 75000, 90000, 80000, 50000],
    "Стаж работы": [2, 5, 15, 7, 3],
}
df = pd.DataFrame(data)
display(df)
```

Рисунок 1. Создание df c помощью ditctъ

Рисунок 2. Создание df c помощью ditcts list

Рисунок 3. Создание df с помощью пр массива

2. Чтение данных из файлов (CSV, Excel, JSON).

```
df_full.to_csv("table1.csv", index=False)
df_csv = pd.read_csv("table1.csv")
```

Рисунок 4. Сохранение df в csv таблицу и загрузка из csv

```
data_full_2 =
    "ID": list(range(1, 21)),
    "Имя": ["Иван", "Ольга", "Алексей", "Мария", "Сергей", "Анна", "Дмитрий", "Елена", "Виктор", "Алиса",
           "Павел", "Светлана", "Роман", "Татьяна", "Николай", "Валерия", "Григорий", "Юлия", "Степан", "Василиса"],
   "Возраст": [34, 27, 45, 38, 29, 50, 31, 40, 28, 33, 46, 37, 41, 25, 39, 42, 49, 50, 30, 35],
   "Город": ["Москва", "Санкт-Петербург", "Казань", "Новосибирск", "Екатеринбург", "Воронеж", "Челябинск", "Краснодар",
             "Ростов-на-Дону", "Уфа", "Омск", "Пермь", "Тюмень", "Саратов", "Самара", "Волгоград", "Барнаул", "Иркутск",
             "Хабаровск", "Томск"],
   "Баланс на счете": [120000, 80000, 150000, 200000, 95000, 300000, 140000, 175000, 110000, 98000,
                        250000, 210000, 135000, 155000, 125000, 180000, 275000, 320000, 105000, 90000],
   "Кредитная история": ["Хорошая", "Средняя", "Плохая", "Хорошая", "Средняя", "Отличная", "Средняя", "Хорошая",
                          "Плохая", "Средняя", "Хорошая", "Отличная", "Средняя", "Хорошая", "Средняя", "Плохая",
                          "Отличная", "Хорошая", "Средняя", "Плохая"]
df = pd.DataFrame(data_full_2)
file_name = 'Клиенты.xlsx'
df.to_excel(file_name, index=False, sheet_name='Клиенты')
```

Рисунок 5. Сохранение таблицы 1 df в csv таблицу и загрузка из csv

```
json_file = 'table_1.json'
df_full.to_json(json_file, orient='records', force_ascii=False)
df_from_json = pd.read_json(json_file)
df_from_json.head()
```

Рисунок 6. Экспорт таблицы 1 в json файл

3.Доступ к данным (.loc , .iloc , .at , .iat).

```
df_1 = pd.DataFrame(data_full)
print(df_1.loc[df_1["ID"] == 5])
```

Рисунок 7. Получение информации о сотруднике с ID =5

```
print(df_1.loc[2]["Возраст"])
```

Рисунок 8. Возраст третьего сотрудника в таблице

```
print(df_1.at[3, "Отдел"])
```

```
print(df_1.iat[3,5])
```

Рисунок 10. Зарплата сотрудника, находящегося в четвертой строке и пятом столбие

4. Добавление новых столбцов и строк.

Рисунок 11. Добавление столбца в таблицу с категориями зарплат

```
df_1.loc[20] = [21,"Антон", 32, "Разработчик", "IT", 85000, 6,"Средняя"] display(df_1.tail())
```

Рисунок 12. Добавление сотрудника в таблицу

```
new_data ={
    "ID": [22, 23],
    "Имя": ["Антон", "Марина"],
    "Возраст": [32, 27],
    "Должность": ["Разработчик", "Менеджер"],
    "Отдел": ["IT", "Продажи"],
    "Зарплата": [85000, 75000],
    "Стаж работы": [6, 5],
    "Категория зарплаты":["Средняя", "Средняя"]

new_df = pd.DataFrame(new_data)
df_1 = pd.concat([df_1, new_df], ignore_index=True)
display(df_1.tail())
```

Рисунок 13. Добавление нескольких сотрудника в таблицу

5. Удаление строк и столбцов.

```
df_1=df_1.drop(columns=['Категория зарплаты'])
display(df_1.head())
```

Рисунок 14. Удаление столбца "Категория зарплаты"

```
df_1_1 = df_1
df_1_1 = df_1_1[df_1_1['ID'] != 10]
display(df_1_1)
```

Рисунок 15. Удаление строки с ID =10

```
df_1_1 = df_1_1[df_1_1['Стаж работы'] >= 3]
display(df_1_1)
```

Рисунок 16. Удаление строк, где стаж работы <3

```
df_1_1 = df_1_1[['Имя', 'Должность', 'Зарплата']]
display(df_1_1)
```

Рисунок 17. Удаление всех столбцов кроме Имя, Должность, Зарплата

5. Фильтрация данных (query, isin, between).

```
df_2=pd.DataFrame(data_full_2)
filters = ["Москва","Санкт-Петербург" ]
filtered_df = df[df['Город'].isin(filters)]
display(filtered_df)
```

Рисунок 18. Выбор всех клиентов из "Москва" или "Санкт-Петербург"

```
filtered_df=df_2[df_2['Баланс на счете'].between(100000, 250000)] display(filtered_df)
```

Рисунок 19. Выбор клиентов, у которых Баланс на счете от 100000 до 250000

```
filtered_df_2 =df.query('`Кредитная история` == "Хорошая" and `Баланс на счете` > 150000') display(filtered_df_2)
```

Рисунок 20. Фильтр клиентов, у которых "Кредитная история" "Хорошая" и "Баланс на счете»> 150000

6.Подсчет значений (count, value_counts, nunique).

```
count_per_column = df_2.count()
print(count_per_column)
```

Рисунок 21. Подсчет количества непустых значений в столбцах

```
count_cities = df["Город"].value_counts()
print(count_cities)
```

Рисунок 22. Подсчет частоты встречаемых городов

```
names = ["Город" , "Возраст" , "Баланс на счете"]
unique = df[names].nunique()
print(unique)
```

Рисунок 23. Количество уникальных значений в "Город", "Возраст", "Баланс на счете"

6.Обнаружение пропусков (isna, notna).

Рисунок 24. df таблицы 3

```
nan_counts = df.isna().sum()
print("Количество NaN в каждом столбце:\n", nan_counts)
```

Рисунок 25. Количество NaN в каждом столбце

```
filled_counts = df.notna().sum()
print("\nКоличество заполненных значений в каждом столбце:\n", filled_counts)
```

Рисунок 26. количество заполненных значений в каждом столбце

```
df_cleaned = df.dropna()
print("\nDataFrame без пропущенных значений:")
display(df_cleaned)
```

Рисунок 27. Строки, где нет пропущенных значений.

7.Выполнил индивидуальное задание.

Индивидуальное задание. Вариант 9

Написать программу на языке программирования Python для решения поставленной задачи (в репозитории должны присутствовать настройки требуемых пакетов для выбранного менеджера пакетов). Приложение должно использовать интерфейс командной строки (модуль argparse) или графический интерфейс пользователя (модули tkinter, PySide2, Kivy и т. д.). При работе с датой и временем использовать пакет datetime . Организовать чтение и сохранение данных из/в формат Parquet. Выполнить валидацию сохраненных данных с помощью сторонних приложений для работы с форматом Parquet, например https://github.com/mukunku/ParquetViewer. Организовать также удаление данных по одной из колонок DataFrame на выбор обучающихся. Номер варианта определяется по согласованию с преподавателем. Использовать DataFrame, содержащий следующие колонки: название начального пункта маршрута; название конечного пункта маршрута; номер маршрута. Написать программу, выполняющую следующие действия: ввод с клавиатуры данных и добавление строк в DataFrame; записи должны быть упорядочены по номерам маршрутов; вывод на экран информации о маршруте, номер которого введен с

клавиатуры; если таких маршрутов нет, выдать на дисплей соответствующее сообщение.

Листинг программы:

```
import pandas as pd
import os
from datetime import datetime
from IPython.display import display, clear_output
import ipywidgets as widgets
class RouteManager:
  def init (self):
     self.df = pd.DataFrame(columns=['start point', 'end point', 'route number', 'created at'])
  def add_route(self, start: str, end: str, number: int):
     """Добавление нового маршрута с автоматической сортировкой"""
     new_route = pd.DataFrame({
       'start_point': [start],
       'end_point': [end],
       'route_number': [number],
       'created_at': [datetime.now()]
     self.df = pd.concat([self.df, new_route], ignore_index=True)
     self.df = self.df.sort_values(by='route_number').reset_index(drop=True)
     return f" ✓ Маршрут № {number} добавлен: {start} → {end}"
  def find_route(self, number: int):
     """Поиск маршрута по номеру"""
     result = self.df[self.df['route_number'] == number]
     return result
  def delete by column(self, column: str, value: str):
     """Удаление записей по значению в колонке"""
     if column in self.df.columns:
       before = len(self.df)
       self.df = self.df[self.df[column] != value]
       return f" Удалено {before - len(self.df)} записей где {column} = {value}"
     return " X Ошибка: неверное название колонки"
  def save_to_parquet(self, filename: str):
     """Сохранение данных в Parquet-формат"""
     self.df.to_parquet(filename, engine='pyarrow')
     return f" Данные сохранены в {filename}"
  def load_from_parquet(self, filename: str):
     """Загрузка данных из Parquet-файла"""
     if os.path.exists(filename):
       self.df = pd.read parquet(filename, engine='pyarrow')
       self.df = self.df.sort_values(by='route_number').reset_index(drop=True)
       return f" Данные загружены из {filename}\nВсего маршрутов: {len(self.df)}"
     return f" X Файл {filename} не найден"
  def show all routes(self):
     """Показать все маршруты"""
     if self.df.empty:
       return " \(\bar{\rmathbb{O}}\) Нет данных о маршрутах"
     return self.df[['start point', 'end point', 'route number']]
```

```
def create_ui():
  """Создание пользовательского интерфейса"""
  manager = RouteManager()
  output = widgets.Output()
  # Виджеты для добавления маршрута
  start_input = widgets.Text(placeholder='Mocквa', description='Oткуда:')
  end_input = widgets.Text(placeholder='Caнкт-Петербург', description='Куда:')
  number input = widgets.IntText(description='Homep:', value=1)
  add_button = widgets.Button(description='Добавить', button_style='success')
  # Виджеты для поиска маршрута
  search_input = widgets.IntText(description='Поиск:', value=1)
  search button = widgets.Button(description='Haйти', button style='info')
  # Виджеты для удаления маршрутов
  column dropdown = widgets.Dropdown(
    options=['Начальный пункт', 'Конечный пункт', 'Номер маршрута'],
    value='Номер маршрута',
    description='Удалить по:'
  value input = widgets.Text(description='Значение:', value=")
  delete button = widgets.Button(description='Удалить', button style='danger')
  # Виджеты для работы с файлами
  filename_input = widgets.Text(value='routes.parquet', description='Файл:')
  save_button = widgets.Button(description='Coxpahuть', button_style='primary')
  load_button = widgets.Button(description='Загрузить', button_style='primary')
  # Обработчики событий
  def on_add_button_clicked(b):
    with output:
      clear output()
      try:
         result = manager.add_route(
           start_input.value,
           end_input.value,
           number_input.value
         print(result)
         display(manager.show_all_routes())
      except Exception as e:
         print(f" Oшибка: {str(e)}")
  def on search button clicked(b):
    with output:
      clear_output()
         routes = manager.find_route(search_input.value)
         if not routes.empty:
           print(f" \ Найденные маршруты № {search_input.value}:")
           display(routes[['start_point', 'end_point', 'route_number']])
            print(f" \( \sqrt{MapupyToB с номером {search_input.value} не найдено")}
      except Exception as e:
         print(f" (—) Ошибка: {str(e)}")
  def on_delete_button_clicked(b):
    with output:
```

```
clear_output()
    try:
       # Преобразование русских названий в английские
       column_map = {
         'Начальный пункт': 'start_point',
         'Конечный пункт': 'end_point',
         'Номер маршрута': 'route_number'
      column = column map[column dropdown.value]
       # Преобразование значения для номера маршрута
      if column == 'route_number':
         value = int(value_input.value)
      else:
         value = value input.value
      result = manager.delete by column(column, value)
       print(result)
       display(manager.show_all_routes())
    except Exception as e:
      print(f" Oшибка: {str(e)}")
def on save button clicked(b):
  with output:
    clear_output()
      print(manager.save to parquet(filename input.value))
    except Exception as e:
      print(f" Oшибка: {str(e)}")
def on_load_button_clicked(b):
  with output:
    clear_output()
    try:
      result = manager.load_from_parquet(filename_input.value)
       print(result)
       display(manager.show_all_routes())
    except Exception as e:
       print(f" O Ошибка: {str(e)}")
# Привязка обработчиков
add_button.on_click(on_add_button_clicked)
search_button.on_click(on_search_button_clicked)
delete_button.on_click(on_delete_button_clicked)
save button.on click(on save button clicked)
load_button.on_click(on_load_button_clicked)
# Группировка виджетов
add_box = widgets.VBox([
  widgets.HTML("<h3>Добавить маршрут</h3>"),
  widgets.HBox([start_input, end_input, number_input, add_button])
search_box = widgets.VBox([
  widgets.HTML("<h3>Поиск маршрута</h3>"),
  widgets.HBox([search_input, search_button])
1)
delete box = widgets.VBox([
  widgets.HTML("<h3>Удалить маршруты</h3>"),
  widgets.HBox([column_dropdown, value_input, delete_button])
])
```

	file_box = widgets.VBox([widgets.HTML(" <h3>Pабота с файлами</h3> "), widgets.HBox([filename_input, save_button, load_button])										
]) # Отобрах	кение интерфейса									
	# Отображение интерфейса display(widgets.VBox([
	widgets. HTML(" <h2 style="color: #1a73e8;"> Управление маршрутами</h2> "),										
	add_box,										
	search_box,										
delete_box,											
file_box,											
	widgets.HTML(" <h3>Peзультат:</h3> "),										
	output										
#Запуск интерфейса											
CI	eate_ui()										
1	∑	ление маршрутами									
	Добавить м	аршрут									
	Откуда:	Москва	Куда: Санкт-	Петербург	Номер: 1		Добавить				
	Поиск марш	ірута									
	Поиск:	1	Найти								
	Удалить ма	ршруты									
	Удалить по:	Номер маршрута	Значение:		Удалить						
	Работа с файлами										
	Файл:	routes.parquet	Сохранить	Загрузить							

Рисунок 28. Интерфейс для программы

Результат:

¬ найденные маршруты №1:

start_point end_point route_number



Рисунок 29. Результат работы программы

8. Сохранил изменения в репозитории

Рисунок 30. Добавление изменений в репозиторий

Ответы на контрольные вопросы:

1. Как создать pandas. Data Frame из словаря списков?

Чтобы создать DataFrame из словаря списков, используйте конструкцию pd.DataFrame():

```
import pandas as pd
data = {'Имя': ['Анна', 'Иван', 'Мария'], 'Возраст': [23, 35, 29]}
df = pd.DataFrame(data)
```

2. В чем отличие создания DataFrame из списка словарей и словаря списков?

Список словарей: каждый словарь представляет строку данных.

Столбцы будут выведены на основе ключей словаря.

```
data = [{'Имя': 'Анна', 'Возраст': 23}, {'Имя': 'Иван', 'Возраст': 35}]
df = pd.DataFrame(data)
```

Словарь списков: ключи словаря — это названия столбцов, а значения — это списки данных, где каждый элемент в списке соответствует строке.

```
data = {'Имя': ['Анна', 'Иван'], 'Возраст': [23, 35]}
df = pd.DataFrame(data)
```

3. Как создать pandas. Data Frame из массива NumPy?

Для создания DataFrame из массива NumPy, передайте его в pd.DataFrame():

```
import numpy as np
import pandas as pd
data = np.array([[1, 2], [3, 4], [5, 6]])
df = pd.DataFrame(data, columns=['A', 'B'])
```

4. Как загрузить DataFrame из CSV-файла, указав разделитель ;?

Для загрузки данных из CSV с разделителем; используйте параметр sep:

```
df = pd.read_csv('data.csv', sep=';')
```

5. Как загрузить данные из Excel в pandas. Data Frame и выбрать конкретный лист?

Для загрузки данных из Excel и указания конкретного листа:

```
df = pd.read_excel('data.xlsx', sheet_name='Лист1')
```

6. Чем отличается чтение данных из JSON и Parquet в pandas?

JSON: используется для работы с текстовыми данными в формате JSON.

```
df = pd.read_json('data.json')
```

Parquet: это бинарный формат, который более эффективен по скорости и использует схемы данных. Он поддерживает типизацию и сжимаемые данные.

```
df = pd.read_parquet('data.parquet')
```

7. Как проверить типы данных в DataFrame после загрузки?

Для проверки типов данных столбцов используйте атрибут .dtypes:

df.dtypes

8. Как определить размер DataFrame (количество строк и столбцов)? Для получения размера используйте атрибут .shape:

9.В чем разница между .loc[] и .iloc[]?

loc[] используется для выбора по меткам (индексам).

.iloc[] используется для выбора по позициям (индексам по порядку).

10. Как получить данные третьей строки и второго столбца с .iloc[]?

Используйте .iloc[] с позициями:

11. Как получить строку с индексом "Мария" из DataFrame?

Используйте .loc[]:

12. Чем .at[] отличается от .loc[]?

.at[] используется для получения одного значения по меткам, быстрее, чем .loc[], но работает только для одного значения (не для целых строк или столбцов).

.loc[] позволяет выбрать более сложные срезы данных.

13. В каких случаях .iat[] работает быстрее, чем .iloc[]?

.iat[] работает быстрее, чем .iloc[], если нужно получить одно значение по позиции, так как .iat[] более специализирован для этого.

14. Как выбрать все строки, где "Город" равен "Москва" или "СПб", используя .isin()?

Для выбора строк с .isin():

```
df[df['Город'].isin(['Москва', 'СПб'])]
```

15. Как отфильтровать DataFrame, оставив только строки, где "Возраст" от 25 до 35 лет, используя .between()?

Для фильтрации с .between():

```
df[df['Возраст'].between(25, 35)]
```

16. В чем разница между .query() и .loc[] для фильтрации данных?

.query() позволяет использовать строковые выражения для фильтрации, что делает код более читаемым и удобным.

.loc[] требует использования явных условий, часто более гибкое, но менее удобное для простых фильтров.

17. Как использовать переменные Python внутри .query()?

Для использования переменных в .query() передайте их через параметр local dict:

```
возраст_min = 25
возраст_max = 35
df.query('Возраст >= @возраст_min and Возраст <= @возраст_max')
```

18. Как узнать, сколько пропущенных значений в каждом столбце DataFrame?

Используйте .isna() и .sum():

```
df.isna().sum()
```

19. В чем разница между .isna() и .notna()?

.isna() возвращает True для пропущенных значений (NaN).

.notna() возвращает True для непустых значений.

20. Как вывести только строки, где нет пропущенных значений?

Для вывода строк без пропущенных значений:

21. Как добавить новый столбец "Категория" в DataFrame, заполнив его фиксированным значением "Неизвестно"?

Добавьте новый столбец:

22. Как добавить новую строку в DataFrame, используя .loc[]?

Используйте .loc[] для добавления строки по новому индексу:

23. Как удалить столбец "Возраст" из DataFrame?

Для удаления столбца используйте drop():

24. Как удалить все строки, содержащие хотя бы один NaN, из DataFrame?

Для удаления строк с NaN:

25. Как удалить столбцы, содержащие хотя бы один NaN, из DataFrame?

Для удаления столбцов с NaN:

26. Как посчитать количество непустых значений в каждом столбце DataFrame?

Для подсчета непустых значений используйте .count():

27. Чем .value_counts() отличается от .nunique()?

.value_counts() возвращает количество уникальных значений в столбце.

.nunique() возвращает количество уникальных значений, но не учитывает их частоту.

28. Как определить сколько раз встречается каждое значение в столбце "Город"?

Используйте .value_counts():

29. Почему display(df) лучше, чем print(df), в Jupyter Notebook?

display(df) в Jupyter отображает DataFrame в виде таблицы с форматированием, что делает данные более читаемыми, в отличие от print(df), который просто выводит их в виде текста.

30. Как изменить максимальное количество строк, отображаемых в DataFrame в Jupyter Notebook?

Чтобы изменить максимальное количество строк, отображаемых в DataFrame в Jupyter Notebook, можно использовать параметр pd.set_option().

Вывод по заданию: Выполнение задания позволило изучить основные функциональные возможности библиотеки pandas при работе с DataFrame.

Вывод: в ходе работы были получены навыки работы с библиотекой pandas, в частности, со структурой данных DataFrame